



机器学习导论

第7章 贝叶斯分类器

谢茂强

南开大学软件学院

基于概率模型的分类器（回顾）

- 定义

- X : 图像集合=



- Y : 识别结果集合= $\{0, 1, 9, M, z\}$

- 任务: 估计以下的概率

- $P(Y=0 \mid x=\text{9})=0.01$
- $P(Y=1 \mid x=\text{9})=0.02$
- $P(Y=9 \mid x=\text{9})=0.95$
- $P(Y=M \mid x=\text{9})=0.01$
- $P(Y=z \mid x=\text{9})=0.01$

- 选择最大估计概率对应的 Y 作为预测结果
- 也可以使用函数来 $y = f(x)$ 表示, 其中

$$f(\mathbf{x}) = \arg \max_{c \in \{0, 1, 9, M, z\}} P(y = c | \mathbf{x})$$

目录

7.1 贝叶斯定理

7.2 朴素贝叶斯分类器

7.3 最大似然估计

7.4 贝叶斯信念网

7.5 基于朴素贝叶斯的文本情感分类预测

7.6 期望最大化算法

7.1 贝叶斯定理 (1763年)

- 由条件概率公式

$$P(A | B) = \frac{P(A \cap B)}{P(B)}$$



$$P(A \cap B) = P(A | B)P(B) = P(B | A)P(A)$$

- 可得贝叶斯公式

$$P(A | B) = \frac{P(B | A)P(A)}{P(B)}$$

- 分母也可根据全概公式进行分解：
$$P(B) = \sum_{i=1}^n P(A_i)P(B|A_i)$$

7.1 从预测角度看估计后验概率 $P(c | \boldsymbol{x})$

$$P(c | \boldsymbol{x}) = \frac{P(c, \boldsymbol{x})}{P(\boldsymbol{x})} = \frac{P(c)P(\boldsymbol{x}|c)}{P(\boldsymbol{x})}$$

$P(\boldsymbol{x})$: 样本 $\boldsymbol{x}$ 在样本空间中出现的概率

$P(\boldsymbol{x}|c)$: 代表样本 $\boldsymbol{x}$ 相对于类别 c 的类条件概率 (class-conditional probability) , 或称为似然 (likelihood)

$P(c)$: $\mathcal{Y}$ 中各 $c \in \mathcal{Y}$ 的先验概率

目录

7.1 贝叶斯定理

7.2 朴素贝叶斯分类器

7.3 最大似然估计

7.4 贝叶斯信念网

7.5 基于朴素贝叶斯的文本情感分类预测

7.6 期望最大化算法

7.2 朴素贝叶斯分类器(Naïve Bayes Classifier)

- 在估计 $P(\mathbf{x}|c)$ 时很难估计 $\mathbf{x}$ 所有维联合发生的概率，原因在于很难用频率估计概率，因此，通过假设“各维度条件独立”，将联合概率的估计变成各维度概率连乘。

$$P(c | \mathbf{x}) = \frac{P(c)P(\mathbf{x}|c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i | c)$$

7.2 朴素贝叶斯分类器的判决函数

- 由于对于给定 x , 其 $P(x)$ 对于所有 $c \in \mathcal{Y}$ 是一样的。
- 朴素贝叶斯的判决函数简化为:

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

7.2 类先验概率、类条件概率的估计

$P(c)$: 使用样本空间中各类样本所占比重来估计。根据大数定理，当训练集包含充足的独立同分布样本时，可使用频率来估计概率。

$$P(\mathbf{x}|c) = P(x_1, x_2, \dots, x_d|c) = \prod_{i=1}^d P(x_i|c)$$

直接使用样本出现频率来估计对关于 所有特征的联合概率将会遇到严重困难——很多种取值未在训练集中出现。（“未被观测到” v.s. “出现概率为0”）

假设样本 d 维特征都是二值的。联合随机事件数 2^d ，独立的事件数 $2d$

7.2 判决函数中的各概率的估计(离散属性)

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

- 类先验概率: $P(c) = \frac{|D_c|}{|D|}$
- 类条件概率:
(离散属性) $P(x_i | c) = \frac{|D_{c,x_i}|}{|D_c|}$

7.2 判决函数中的各概率的估计(连续属性)

$$h_{nb}(\mathbf{x}) = \arg \max_{c \in \mathcal{Y}} P(c) \prod_{i=1}^d P(x_i | c)$$

- 类先验概率: $P(c) = \frac{|D_c|}{|D|}$
- 类条件概率: $P(x_i | c) = \frac{1}{\sqrt{2\pi}\sigma_{c,i}} \exp \left(-\frac{(x_i - \mu_{c,i})^2}{2\sigma_{c,i}^2} \right)$
(连续属性)
- 第 c 类样本在第 i 个属性上取值的 $\mu_{c,i}$ 和 $\sigma_{c,i}^2$

7.2 估计 $P(x|c)$ 和 $P(c)$ 时碰到的问题

- 训练样本不充足，导致概率估计为零。
- 可以进行“平滑” smoothing。比如拉普拉斯修正 (Laplacian Correction)

$$\hat{P}(c) = \frac{|D_c| + 1}{|D| + N} ,$$

N : 数据集中的类别数

$$\hat{P}(x_i | c) = \frac{|D_{c,x_i}| + 1}{|D_c| + N_i} .$$

N_i : 第 i 维特征的可能取值数

7.2 总结：朴素Bayes分类器的训练

1. 数据预处理（特征的离散化或估计样本分布参数）
2. 估计每个类别的类先验概率 $P(c)$ 并存储下来
3. 估计每个类别条件下各特征下每种取值出现的概率 $P(x_i|c)$ 并存储下来

7.2 总结：朴素Bayes分类器的预测算法

1. 数据预处理(按照训练的预处理方法进行)
2. 利用预计算好的 $P(c)$ 和 $P(\mathbf{x}_i|c)$, 根据贝叶斯公式为每个类别 c 计算

$$P(c|\mathbf{x}) = \frac{P(c)P(\mathbf{x}|c)}{P(\mathbf{x})} = \frac{P(c)}{P(\mathbf{x})} \prod_{i=1}^d P(x_i|c)$$

3. 选择最大后验概率对应的类别作为结果输出。

$$y = \arg \max_c P(c|\mathbf{x})$$

插播：贝叶斯分类器是生成式模型

- 生成式模型 (Generative Models)
 - 需要先对生成样本的分布进行估计，然后再估计 $P(c | \mathbf{x})$

$$P(\mathbf{x}, c) = P(\mathbf{x} | c) P(c)$$

- 判决式模型 (Discriminative Models)
 - 直接建模 $P(y = c | \mathbf{x})$ (即直接求解判决模型(参数))

目录

7.1 贝叶斯定理

7.2 朴素贝叶斯分类器

7.3 最大似然估计

7.4 贝叶斯信念网

7.5 基于朴素贝叶斯的文本情感分类预测

7.6 期望最大化算法

7.3 最大似然估计 (MLE , Maximum Likelihood Estimation)

- 概率分布的参数估计(parameter estimation)
 - 先假定某随机事件的概率符合某种确定的分布形式，可基于抽样数据（训练数据）对概率分布的参数进行估计。
 - 从机器学习的角度可以将参数估计看成模型训练
- 对于NB所需的 $P(x|c)$ ，可假设其形式，且被参数 θ_c 唯一确定，那么使用训练集训练概率模型的任务，其实就是数理统计中的估计参数 θ_c

7.3 最大似然估计

似然函数：是用于表示在参数为 θ 的分布下观测到样本 x 的可能性

假设训练数据集 D 的 m 个样本是相互独立采样得来的

$$P(D | \theta) = \prod_{x \in D} P(x | \theta)$$

计算似然过程中涉及连乘，且概率均在 $[0,1]$ 区间内，这会导致样本数量大时，极易造成下溢，所以，多采用对数似然

$$LL(\theta) = \log P(D | \theta) = \sum_{x \in D} \log P(x | \theta)$$

下溢：计算结果小于计算机所能表示的最小正数，从而被强制截断为0的现象

7.3 最大似然估计

在枚举参数 θ 的所有可能取值或取值组合后，选择最大对数似然对应的分布。
也就是最大似然的分布生成训练数据 D 的可能性最大

对应的分布参数为：

$$\hat{\theta} = \arg \max_{\theta} LL(\theta)$$

7.3.2 基于最大似然估计Logistic回归的参数

定义样本的后验概率：

$$p(y = 1 \mid \mathbf{x}; \mathbf{w}) = \frac{1}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = f_{\mathbf{w}}(\mathbf{x})$$

$$p(y = 0 \mid \mathbf{x}; \mathbf{w}) = 1 - p(y = 1 \mid \mathbf{x}; \mathbf{w}) = \frac{e^{-\mathbf{w}^T \mathbf{x}}}{1 + e^{-\mathbf{w}^T \mathbf{x}}} = 1 - f_{\mathbf{w}}(\mathbf{x})$$

基于后验概率定义训练样本与预测模型之间的似然函数：

$$P(y \mid \mathbf{x}; \mathbf{w}) = f_{\mathbf{w}}(\mathbf{x})^y (1 - f_{\mathbf{w}}(\mathbf{x}))^{1-y}$$

7.3.2 基于最大似然估计Logistic回归的参数

对数似然：

$$LL(\mathbf{w}) = \log \prod_{i=1}^m p\left(y^{(i)} \mid \mathbf{x}^{(i)}; \mathbf{w}\right)$$

$$= \sum_{i=1}^m \log p\left(y^{(i)} \mid \mathbf{x}^{(i)}; \mathbf{w}\right)$$

$$= \sum_{i=1}^m \log \left(f_{\mathbf{w}}(\mathbf{x}^{(i)})^{y^{(i)}} \left(1 - f_{\mathbf{w}}(\mathbf{x}^{(i)})\right)^{1-y^{(i)}} \right)$$

$$= \sum_{i=1}^m \left(y^{(i)} \log \left(f_{\mathbf{w}}(\mathbf{x}^{(i)}) \right) + \left(1 - y^{(i)}\right) \log \left(1 - f_{\mathbf{w}}(\mathbf{x}^{(i)})\right) \right)$$

和基于二元交叉熵的
代价函数有何区别？

基于最大对数似然获得最优参数

$$\hat{\mathbf{w}} = \arg \max_{\mathbf{w}} LL(\mathbf{w})$$

目录

7.1 贝叶斯定理

7.2 朴素贝叶斯分类器

7.3 最大似然估计

7.4 贝叶斯信念网

7.5 基于朴素贝叶斯的文本情感分类预测


7.6 期望最大化算法

7.4 贝叶斯信念网 (Bayes Belief Network)

- 朴素贝叶斯分类器属性条件独立性假设在某些任务中不满足
- 多维变量中联合概率估计时属性组合爆炸问题，对样本分布和样本量要求剧增
- 贝叶斯信念网使用有向无环图来描述特征间的条件依赖关系，进而用来计算联合概率分布

7.4 贝叶斯信念网

- 使用有向无环图来描述特征间的条件依赖关系
- 使用条件概率表来描述属性（或特征）的条件概率分布。



	$x_1 = 1$	$x_1 = 1$	$x_1 = 0$	$x_1 = 0$
	$x_2 = 1$	$x_2 = 0$	$x_2 = 1$	$x_2 = 0$
$x_4 = 1$	0.9	0.3	0.5	0.1
$x_4 = 0$	0.1	0.7	0.5	0.9

因为 x_4 依赖于 x_1 和 x_2 ，由此得 $P(x_1, x_2, x_4) = P(x_4 | x_1, x_2)P(x_1)P(x_2)$

$$P(x_1, x_2, x_3, x_4, x_5, x_6) = P(x_1)P(x_2)P(x_3 | x_1)P(x_4 | x_1, x_2)P(x_5 | x_3)P(x_6 | x_3, x_4)$$

7.4.2 贝叶斯信念网的学习（网络结构已知）

- 方法1：
 - 通过统计特征取值频率估计每个特征的条件概率表，进而计算后验概率
- 方法2：
 - 使用最大对数似然 $\log(P(D|w))$ 来估计条件概率表

定义数据集和条件概率表间的似然：
$$\ln P_w(D) = \sum_{l=1}^m \ln P_w(\mathbf{x}_l)$$

$$\ln P_w(\mathbf{x}_l) = \sum_{j,k} \ln P_w(\mathbf{x}_l \mid Y_i = y_{ij}, U_i = u_{ik}) P_w(Y_i = y_{ij}, U_i = u_{ik})$$

目标特征表示为 Y_i ，其父节点集合表示为 $U_{i=\text{parent}(Y_i)}$

7.4.2 贝叶斯信念网的学习（网络结构已知）

对其进行求导获得梯度

$$\begin{aligned}
 \frac{\partial \ln P_w(D)}{\partial w_{ijk}} &= \sum_{l=1}^m \frac{\partial \ln P_w(\mathbf{x}_l)}{\partial w_{ijk}} \\
 &= \sum_{l=1}^m \frac{1}{P_w(\mathbf{x}_l)} \frac{\partial P_w(\mathbf{x}_l)}{\partial w_{ijk}} \\
 &= \sum_{l=1}^m \frac{1}{P_w(\mathbf{x}_l)} \frac{\partial}{\partial w_{ijk}} \sum_{j',k'} P_w(\mathbf{x}_l | y_{ij'}, u_{ik'}) P(y_{ij'}, u_{ik'}) \\
 &= \sum_{l=1}^m \frac{1}{P_w(\mathbf{x}_l)} \frac{\partial}{\partial w_{ijk}} \sum_{j',k'} P_w(\mathbf{x}_l | y_{ij'}, u_{ik'}) P(y_{ij'} | u_{ik'}) P(u_{ik'})
 \end{aligned}$$

求导时，只有 $j'=j$ 且 $k'=k$ 的项会被计算，且 $w_{ijk} := P(Y_i = y_{ij} | U_i = u_{ik})$

$$\frac{\partial \ln P_w(D)}{\partial w_{ijk}} = \sum_{l=1}^m \frac{1}{P_w(\mathbf{x}_l)} P_w(\mathbf{x}_l | y_{ij}, u_{ik}) P_w(u_{ik})$$

7.4.2 贝叶斯信念网的学习（网络结构已知）

根据贝叶斯公式
$$P_w(\mathbf{x}_l | y_{ij}, u_{ik}) = \frac{P_w(y_{ij}, u_{ik} | \mathbf{x}_l) P_w(\mathbf{x}_l)}{P_w(y_{ij}, u_{ik})}$$

可得：

$$\begin{aligned} \frac{\partial \ln P_w(D)}{\partial w_{ijk}} &= \sum_{l=1}^m \frac{P_w(y_{ij}, u_{ik} | \mathbf{x}_l) P_w(u_{ik})}{P_w(y_{ij}, u_{ik})} \\ &= \sum_{l=1}^m \frac{P_w(y_{ij}, u_{ik} | \mathbf{x}_l)}{P_w(y_{ij} | u_{ik})} \\ &= \sum_{l=1}^m \frac{P_w(y_{ij}, u_{ik} | \mathbf{x}_l)}{w_{ijk}} \end{aligned}$$

之后，根据梯度上升法，通过最大化对数似然获得条件概率表。

7.4.2 贝叶斯信念网的学习（网络结构未知）

- 方法1：
 - 基于评分的贪心搜索：BIC(Bayesian Information Criterion), AIC(Akaike Information Criterion)。通过二者度量网络结构和训练数据的似然。进而获得最匹配的网络结构
- 方法2：
 - 基于约束的学习：通过统计检验判定节点间是否条件独立
- 实践中，往往二者结合

目录

7.1 贝叶斯定理

7.2 朴素贝叶斯分类器

7.3 最大似然估计

7.4 贝叶斯信念网

7.5 基于朴素贝叶斯的文本情感分类预测

7.6 期望最大化算法

7.5 基于朴素贝叶斯的文本情感分类预测

以判断手机用户评论的情感倾向为例

$$Sentiment = \frac{P(Y = 1 | S)}{P(Y = 0 | S)}$$

主要判断

$P(Y = 1 | S)$ 和 $P(Y = 0 | S)$ 谁大？

1: 正向情感、0: 负向情感

用户评论	情感倾向	情感倾向
你这个版本非常牛逼续航强	正向	1
手机外观漂亮，材质手感好非常喜欢，物超所值性价比高，二千多买到这配置的手机不错了。之前的手机用了三年电池不赖用了，所以换个续航长电池容量大的手机	正向	1
还好我没更新橘子5，现在最后一版橘子4，续航很好	正向	1
挺好看，时尚，轻便，用着挺流畅	正向	1
运行速度很快，能耗也不错	正向	1
好端端的怎么连不上网络了	负向	0
容易脱皮，用几个月就不行了	负向	0
点开应用后应用画面与游戏魔盒方向相反	负向	0
打完视频挂断红，还会显示在打电话	负向	0

7.5 估计P(S)的语言模型

- 语言模型(Language Model)的核心是估计句子(Sentence)被生成的概率

$$\begin{aligned} P(S) &= P(w_1, w_2, w_3, \dots, w_k) \\ &= P(w_1)P(w_2|w_1)P(w_3|w_2, w_1) \dots P(w_k|w_{k-1}, w_{k-2} \dots w_1) \end{aligned}$$

其中，句子 S 由单词 w_i 组合而成。

- 条件概率 $P(w_k|w_{k-1}, w_{k-2} \dots w_1)$ 的估计对样本量的需求巨大，例如，在估计下述概率得0可能性很大。

7.5 N-gram语言模型

Markov 假设:下一个词出现的概率仅依赖前面一个或几个词

- 1-gram (Unigram,不依赖前面的词)

$$P(S) = P(w_1)P(w_2)P(w_3) \cdots P(w_k)$$

- 2-gram (Bigram,依赖前面一个词)

$$P(S) = P(w_1)P(w_2|w_1)P(w_3|w_2) \cdots P(w_k|w_{k-1})$$

- 3-gram (Trigram,依赖前面两个词)

$$P(S) = P(w_1)P(w_2|w_1)P(w_3|w_2, w_1) \cdots P(w_k|w_{k-1}, w_{k-2})$$

7.5 文本情感分类 (Sentiment Classification)



基于贝叶斯定理，分解 $P(Y = 1 | S)$ 和 $P(Y = 0 | S)$

$$Sentiment = \frac{P(Y = 1|S)}{P(Y = 0|S)} = \frac{P(S|Y = 1)P(Y = 1)}{P(S|Y = 0)P(Y = 0)}$$

使用语言模型N-gram来估计 $P(S)$

$$P(S) = P(w_1) P(w_2 | w_1) P(w_3 | w_2, w_1) \cdots P(w_k | w_{k-1}, w_{k-2})$$

基于频率估计条件概率

$$P(w_t | w_{t-1}, y) = \frac{C(w_{t-1}, w_t, y) + 1}{C(w_{t-1}, y) + |V|}$$

统计某种情感下，一词出现后，另一词出现的概率

7.5 二元组 (bi-gram) 化

输入数据S	二元词序	情感分类y
我喜欢香蕉	<s>我, 我喜欢, 喜欢香蕉, 香蕉</s>	1
我喜欢锻炼	<s>我, 我喜欢, 喜欢锻炼, 锻炼</s>	1
我爱看书	<s>我, 我爱, 爱看书, 看书</s>	1
我不讨厌音乐	<s>我, 我不, 不讨厌, 讨厌音乐, 音乐</s>	1
我不讨厌看书	<s>我, 我不, 不讨厌, 讨厌看书, 看书</s>	1
我讨厌香蕉	<s>我, 我讨厌, 讨厌香蕉, 香蕉</s>	0
我讨厌锻炼	<s>我, 我讨厌, 讨厌锻炼, 锻炼</s>	0
我不爱看书	<s>我, 我不, 不爱, 爱看书, 看书</s>	0
我不喜欢音乐	<s>我, 我不, 不喜欢, 喜欢音乐, 音乐</s>	0
我讨厌音乐	<s>我, 我讨厌, 讨厌音乐, 音乐</s>	0
我讨厌看书	<s>我, 我讨厌, 讨厌看书, 看书</s>	0

7.5 正向情感条件 $P(S|y = 1)$

以判别句子 $S=\{<s>,我,不,讨厌,锻炼,</s>\}$ 的情感类别为例

$$p(我|<s>,y=1)=\frac{5+1}{5+|V|}=\frac{6}{16}=0.375000$$

$$p(不|我,y=1)=\frac{2+1}{5+|V|}=\frac{3}{16}=0.187500$$

$$p(讨厌|不,y=1)=\frac{2+1}{2+|V|}=\frac{3}{13}=0.230769$$

$$p(锻炼|讨厌,y=1)=\frac{0+1}{2+|V|}=\frac{1}{13}=0.076923$$

$$p(</s>|锻炼,y=1)=\frac{1+1}{1+|V|}=\frac{2}{12}=0.166667$$

$$P(S|y=1)=0.000208$$

7.5 负向情感条件 $P(S|y = 0)$

以判别句子 $S=\{<s>,我,不,讨厌,锻炼,</s>\}$ 的情感类别为例

$$p(我|<s>,y=0)=\frac{6+1}{6+|V|}=\frac{7}{17}=0.411765$$

$$p(不|我,y=0)=\frac{2+1}{6+|V|}=\frac{3}{17}=0.176471$$

$$p(讨厌|不,y=0)=\frac{0+1}{2+|V|}=\frac{1}{13}=0.076923$$

$$p(锻炼|讨厌,y=0)=\frac{1+1}{4+|V|}=\frac{2}{15}=0.133333$$

$$p(</s>|锻炼,y=0)=\frac{1+1}{1+|V|}=\frac{2}{12}=0.16666$$

$$P(S|y=0)=0.000124$$

7.5 最后情感类别判定

7.5 文本情感分类 (Sentiment Classification)



基于贝叶斯定理, 分解 $P(Y = 1 | S)$ 和 $P(Y = 0 | S)$

$$Sentiment = \frac{P(Y = 1|S)}{P(Y = 0|S)} = \frac{P(S|Y = 1)P(Y = 1)}{P(S|Y = 0)P(Y = 0)}$$

使用语言模型N-gram来估计 $P(S)$

$$P(S) = P(w_1) P(w_2 | w_1) P(w_3 | w_2, w_1) \cdots P(w_k | w_{k-1}, w_{k-2})$$

基于频率估计条件概率 $P(w_t | w_{t-1}, y) = \frac{C(w_{t-1}, w_t, y) + 1}{C(w_{t-1}, y) + |V|}$

统计某种情感下, 一词出现后, 另一词出现的概率

33

$$Sentiment = \frac{P(S|y = 1)P(y = 1)}{P(S|y = 0)P(y = 0)} = \frac{P(S|y = 1) \times 0.4545}{P(S|y = 0) \times 0.5455} \approx 1.3956$$

目录

7.1 贝叶斯定理

7.2 朴素贝叶斯分类器

7.3 最大似然估计

7.4 贝叶斯信念网

7.5 基于朴素贝叶斯的文本情感分类预测

7.6 期望最大化算法

7.6 EM算法

- 最初解决数据缺失条件下的参数估计问题
- 思路
 - 用估计的分布（模型参数）估计缺失数据
 - 整合原有数据和补齐数据重新估计分布（参数）
 - 反复迭代直至收敛
- 目前主要用于存在隐含变量的分布估计上。

7.6 EM算法

- 分布生成的未被观测的随机事件用 Z 表示，使用 Z 所有可能下的模型生成训练数据概率的期望来表示似然

$$P(X|\theta) = P(X, Z|\theta) = \sum_Z P(X|Z, \theta)P(Z|\theta)$$

- 最后使用极大似然法估计模型参数

$$\hat{\theta} = \arg \max_{\theta} \ln P(X, Z|\theta)$$

7.6 EM算法

- 初始化分布参数 θ_0
- 交替执行E步和M步，直至收敛到局部最优解

- E步(Expectation):

- 固定 θ_t ，求隐变量 Z 的后验概率 $q(Z) = P(Z|D, \theta_t) = \frac{P(D, Z|\theta_t)}{P(D|\theta_t)}$


- M步(Maximization):

- 固定 $q(Z)$ ，求 $\theta_{t+1} = \arg \max_{\theta} Q(\theta|\theta_t)$
 $= \arg \max_{\theta} q(Z) \log P(D, Z|\theta)$

7.6 EM算法迭代优化示意

由于数据与分布间的似然引入了隐变量 Z ，因此使用关于 Z 的似然期望来替代。

EM算法通过最大似然估计得到的分布参数不断更新 Z ，这样便能降低似然期望，使其更逼近完整数据的似然。



7.6 EM算法用途

- EM算法多用于带有隐变量的分布参数估计
 - KMeans聚类算法
 - 高斯混合模型(Gaussian Mixture Model)
 - HMM模型参数估计的Baum-Welch 算法等

Kmeans和高斯混合模型将在本课第10章中讲解

- 贝叶斯定理
- 朴素贝叶斯分类器 (Naïve Bayes Classifier)
- 极大似然估计 (Maximum Likelihood Estimation, MLE)
- 贝叶斯信念网 (Bayes Belief Network)
- 贝叶斯与NLP中的语言模型 (Language Model)
- EM (期望最大化) 算法